Notes de leçon | Regroupement et résumé des données

February 2024

Introduction

Vous savez déjà comment conserver les jeux données qui vous intéressent, comment garder les variables pertinentes et comment les modifier ou en créer de nouvelles.

Maintenant, nous allons aller un peu plus loin dans la manipulation de vos données en comprenant comment extraire facilement des statistiques récapitulatives, grâce au verbe `summarize()`, comme le calcul de la moyenne d'une variable.

De plus, nous commencerons à explorer un verbe crucial, `group_by()`, capable de regrouper vos variables ensemble pour effectuer des opérations groupées sur votre jeu de données.

Allons-y !

Objectifs d'apprentissage

1. Vous pouvez utiliser `dplyr::summarize()` pour extraire des statistiques récapitulatives des jeux de données.

2. Vous pouvez utiliser `dplyr::group_by()` pour regrouper les données par une ou plusieurs variables avant d'effectuer des opérations sur elles.

3. Vous comprenez pourquoi et comment dégrouper les jeux de données groupés.

4. Vous pouvez utiliser `dplyr::n()` avec `group_by()`-`summarize()` pour compter les lignes par groupe.

5. Vous pouvez utiliser `sum()` avec `group_by()-summarize()` pour compter les lignes qui répondent à une condition.

6. Vous pouvez utiliser `dplyr::count()` comme une fonction pratique pour compter les lignes par groupe.

Le jeu de données COVID-19 de Yaoundé

Dans cette leçon, nous allons à nouveau utiliser les données de l'enquête sérologique COVID-19 menée à Yaoundé, au Cameroun.

```
<- read_csv(here::here('data/fr_yaounde_data.csv'))

us-ensemble plus petit de variables
vaounde %>% select(
cat_age_3, sexe, poids_kg, taille_cm,
ier, fumeur, enceinte, occupation,
haisons_traitement, symptomes, jours_absence_travail, jours_alite,
aute, resultat_igg)
```

```
## # A tibble: 971 × 15
##       age cat_age_3 sexe   poids_kg
##     <dbl> <chr>     <chr>     <dbl>
##  1     45 Adult     Female       95
##  2     55 Adult     Male         96
##  3     23 Adult     Male         74
##  4     20 Adult     Female       70
##  5     55 Adult     Female       67
##  6     17 Child     Female       65
##  7     13 Child     Female       65
##  8     28 Adult     Male         62
##  9     30 Adult     Male         73
## 10     13 Child     Female       56
##    taille_cm quartier    fumeur
##        <dbl> <chr>       <chr>
##  1       169 Briqueterie Non-smoker
##  2       185 Briqueterie Ex-smoker
##  3       180 Briqueterie Smoker
##  4       164 Briqueterie Non-smoker
##  5       147 Briqueterie Non-smoker
##  6       162 Briqueterie Non-smoker
##  7       150 Briqueterie Non-smoker
##  8       173 Briqueterie Non-smoker
##  9       170 Briqueterie Non-smoker
## 10       153 Briqueterie Non-smoker
```

```
## # ℹ 961 more rows
## # ℹ 8 more variables: enceinte <chr>, occupation <chr>, …
```

Consultez la première leçon de ce chapitre pour plus d'informations sur ce jeu de données.

Qu'est-ce qu'une statistique récapitulative ?

Une statistique récapitulative est une valeur unique (telle qu'une moyenne ou une médiane) qui décrit une séquence de valeurs (généralement une colonne dans votre jeu de données).

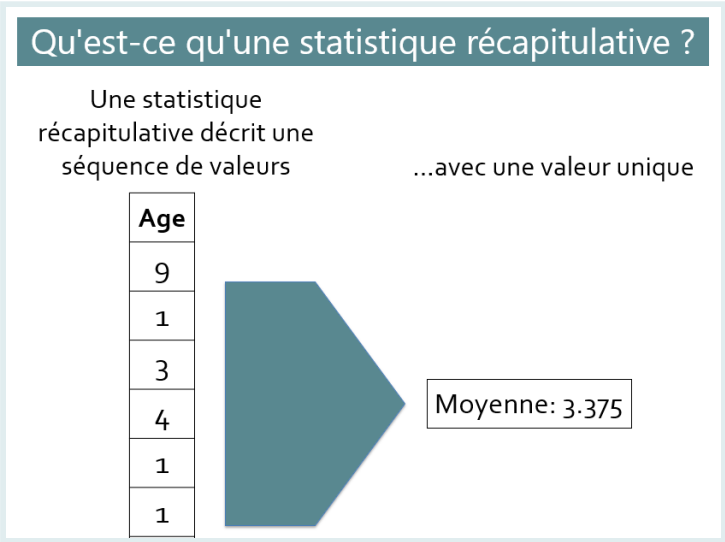

Les statistiques récapitulatives peuvent décrire le centre, la dispersion ou l'étendu d'une variable, ou les nombres et les positions des valeurs au sein de cette variable. Certaines statistiques récapitulatives courantes sont présentées dans le diagramme ci-dessous :

Exemples de statistiques récapitulatives

```
age <- (9, 1, 4, 2, 2, 2)
```

Statistique récapitulative	Code R	Résultat
Nombres		
No. d'éléments	`dplyr::n(age)`	6
No. d'éléments distincts	`dplyr::n_distinct(age)`	4
Position		
Premier élément	`dplyr::first(age)`	9
Dernier élément	`dplyr::last(age)`	2
3ème élément	`dplyr::nth(age, 3)`	4
Centre		
Moyenne	`mean(age)`	3.3
Médiane	`median(age)`	2
Dispersion		
Ecart-type	`sd(age)`	2.9
Ecart interquartile	`IQR(age)`	1.5
Etendu		
Minimum	`min(age)`	1
Maximum	`max(age)`	9
25ème quantile	`quantile(age, 0.25)`	2

Le calcul des statistiques récapitulatives est une opération très courante dans la plupart des processus d'analyse de données, il sera donc important de devenir compétent pour les extraire de vos jeux de données. Et pour cette tâche, il n'y a pas de meilleur outil que la fonction `summarize()` de {dplyr} ! Alors voyons comment utiliser cette puissante fonction.

Introduction à `dplyr::summarize()`

Pour commencer, il est préférable de voir d'abord comment obtenir des statistiques récapitulatives simples *sans* utiliser `summarize()`, puis nous verrons pourquoi vous devriez *réellement* utiliser `summarize()`.

Imaginez que l'on vous demande de trouver l'âge moyen des répondants dans le jeu de données `yao`. Comment pourriez-vous le faire en R de base ?

Tout d'abord, rappelons que la fonction du signe dollar, `$`, vous permet d'extraire une colonne d'un jeu de données vers un vecteur :

```
# extraire la colonne `age` de `yao`
```

Pour obtenir la moyenne, vous passez simplement ce vecteur `yao$age` dans la fonction `mean()` :

```
›$age)
```

```
## [1] 29.01751
```

Et c'est tout ! Vous avez maintenant une statistique récapitulative simple. Extrêmement facile, n'est-ce pas ?

Alors, pourquoi avons-nous besoin de `summarize()` pour obtenir des statistiques récapitulatives si le processus est déjà si simple sans lui ? Nous reviendrons sur la question du *pourquoi* bientôt. D'abord, voyons *comment* obtenir des statistiques récapitulatives avec `summarize()`.

En revenant à l'exemple précédent, la syntaxe correcte pour obtenir l'âge moyen avec `summarize()` serait :

```
ɪize(mean_age = mean(age))
```

```
## # A tibble: 1 × 1
##   mean_age
##      <dbl>
## 1     29.0
```

L'anatomie de cette syntaxe est présentée ci-dessous. Vous devez simplement entrer le nom de la nouvelle colonne (par exemple `mean_age`), la fonction récapitulative (par exemple `mean()`), et la colonne à résumer (par exemple `age`).

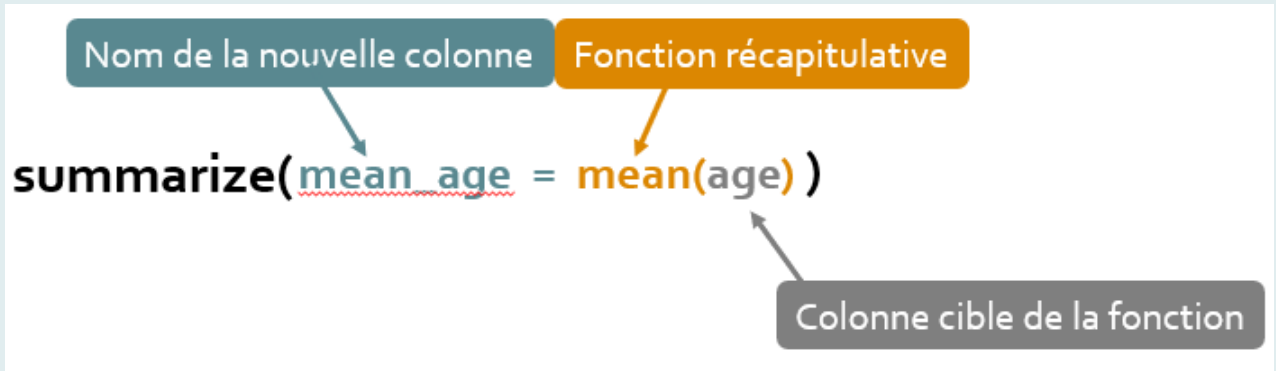

Fig. Syntaxe de base pour la fonction `summarize()`.

Vous pouvez également calculer plusieurs statistiques récapitulatives dans une seule commande `summarize()`. Par exemple, si vous vouliez à la fois l'âge moyen et l'âge médian, vous pourriez exécuter :

```
ɪize(mean_age = mean(age),
     median_age = median(age))
```

```
## # A tibble: 1 × 2
##   mean_age median_age
##      <dbl>      <dbl>
## 1     29.0         26
```

Sympa !

Maintenant, vous devriez vous demander pourquoi `summarize()` place les statistiques récapitulatives dans un jeu de données, avec chaque statistique dans une colonne différente.

Le principal avantage de cette structure de jeu de données est de faciliter la production de résumés *groupés* (et la création de tels résumés groupés sera le principal avantage de l'utilisation de `summarize()`).

Nous examinerons ces résumés groupés dans la section suivante. Pour l'instant, essayez de répondre aux questions de pratique ci-dessous.

Utilisez `summarize()` et les fonctions récapitulatives pertinentes pour obtenir la moyenne, la médiane et l'écart type des poids des répondants à partir de la variable `poids_kg` du jeu de données `yao`.

Votre sortie doit être un jeu de données avec trois colonnes nommées comme indiqué ci-dessous :

mean_poids_kg	median_poids_kg	sd_poids_kg

```
_poids <-
% "ÉCRIVEZ_VOTRE_RÉPONSE_ICI"
```

Utilisez `summarize()` et les fonctions récapitulatives pertinentes pour obtenir les tailles minimale et maximale des répondants à partir de la variable `taille_cm` du jeu de données `yao`.

Votre sortie doit être un jeu de données avec deux colonnes nommées comme indiqué ci-dessous :

min_taille_cm	max_taille_cm

```
_taille <-
%
VEZ_VOTRE_RÉPONSE_ICI"
```

Résumés groupés avec `dplyr::group_by()`

Comme son nom l'indique, `dplyr::group_by()` vous permet de regrouper un jeu de données par les valeurs d'une variable (par exemple le sexe masculin vs féminin). Vous pouvez ensuite effectuer des opérations qui sont divisées selon ces groupes.

Quel effet `group_by()` a-t-il sur un jeu de données ? Essayons de regrouper le jeu de données `yao` par sexe et observons l'effet :

```
by(sexe)
```

```
## # A tibble: 971 × 15
## # Groups:   sexe [2]
##       age cat_age_3 sexe   poids_kg
##     <dbl> <chr>     <chr>     <dbl>
##  1     45 Adult     Female       95
##  2     55 Adult     Male         96
##  3     23 Adult     Male         74
##  4     20 Adult     Female       70
##  5     55 Adult     Female       67
##  6     17 Child     Female       65
##  7     13 Child     Female       65
##  8     28 Adult     Male         62
##  9     30 Adult     Male         73
## 10     13 Child     Female       56
##    taille_cm quartier    fumeur
##        <dbl> <chr>       <chr>
##  1       169 Briqueterie Non-smoker
##  2       185 Briqueterie Ex-smoker
##  3       180 Briqueterie Smoker
##  4       164 Briqueterie Non-smoker
##  5       147 Briqueterie Non-smoker
##  6       162 Briqueterie Non-smoker
##  7       150 Briqueterie Non-smoker
##  8       173 Briqueterie Non-smoker
##  9       170 Briqueterie Non-smoker
## 10       153 Briqueterie Non-smoker
## # ℹ 961 more rows
## # ℹ 8 more variables: enceinte <chr>, occupation <chr>, …
```

Hmm. Apparemment, rien ne s'est passé. La seule chose que vous *pourriez* remarquer est une nouvelle section dans l'en-tête qui vous indique la variable groupée—sex—et le nombre de groupes—2 :

```
  # A tibble: 971 × 10
👉# Groups:   sexe [2]👈
```

Mis à part cet en-tête, cependant, le jeu de données semble inchangé.

Mais voyez ce qui se passe lorsque nous chaînons le `group_by()` avec l'appel `summarize()` que nous avons utilisé dans la section précédente :

```
_by(sexe) %>%
ize(mean_age = mean(age))
```

```
## # A tibble: 2 × 2
##   sexe   mean_age
##   <chr>     <dbl>
## 1 Female     29.5
## 2 Male       28.4
```

Vous obtenez une statistique récapitulative différente pour chaque groupe ! Les statistiques pour les femmes sont dans une ligne et celles pour les hommes sont dans une autre. (À partir de ce jeu de données de sortie, vous pouvez dire par exemple que, l'âge moyen pour les répondantes est de 29.5, tandis que pour les répondants masculins, il est de 28.4)

Comme mentionné précédemment, ce type de résumé groupé est la raison principale pour laquelle la fonction `summarize()` est si utile !

Voyons un autre exemple d'une opération simple `group_by()` + `summarize()`.

Supposons que l'on vous ait demandé d'obtenir les poids maximum et minimum pour les individus dans différents quartiers dans le jeu de données `yao`. D'abord, vous feriez un `group_by()` sur la variable `neighbourhood`, puis vous appeleriez les fonctions `max()` et `min()` à l'intérieur de `summarize()` :

```
_by(quartier) %>%
ize(max_poids = max(poids_kg),
    min_poids = min(poids_kg))
```

```
## # A tibble: 9 × 3
##   quartier     max_poids min_poids
##   <chr>            <dbl>     <dbl>
## 1 Briqueterie        128        20
## 2 Carriere           129        14
## 3 Cité Verte         118        16
## 4 Ekoudou            135        15
## 5 Messa               96        19
## 6 Mokolo             162        16
## 7 Nkomkana           161        15
## 8 Tsinga             105        15
## 9 Tsinga Oliga       100        17
```

Super ! Avec seulement quelques lignes de code, vous êtes capable d'extraire beaucoup d'informations.

Voyons encore un exemple pour faire bonne mesure. La variable `jours_absence_travail` nous indique le nombre de jours où les répondants ont été absents au travail en raison de symptômes similaires à ceux du COVID. Les individus qui n'ont signalé aucun symptôme semblable à celui du COVID ont un `NA` pour cette variable :

```
t(jours_absence_travail)
```

```
## # A tibble: 971 × 1
##    jours_absence_travail
##                    <dbl>
##  1                     0
##  2                    NA
##  3                    NA
##  4                     7
##  5                    NA
##  6                     7
##  7                     0
##  8                     0
##  9                     0
## 10                    NA
## # ℹ 961 more rows
```

Pour compter le nombre total de jours de travail manqués pour chaque groupe de sexe, vous pourriez essayer d'exécuter la fonction `sum()` sur la variable `jours_absence_travail` :

```
_by(sexe) %>%
rise(total_jours_absence = sum(jours_absence_travail))
```

```
## # A tibble: 2 × 2
##   sexe   total_jours_absence
##   <chr>                <dbl>
## 1 Female                  NA
## 2 Male                    NA
```

Hmmm. Cela vous donne des résultats `NA` car certaines lignes dans la colonne `jours_absence_travail` ont des `NA` en elles, et R ne peut pas trouver la somme de valeurs contenant un `NA`. Pour résoudre ce problème, l'argument `na.rm = TRUE` est nécessaire :

```
_by(sexe) %>%
rise(total_jours_absence = sum(jours_absence_travail, na.rm = TRUE))
```

```
## # A tibble: 2 × 2
##   sexe   total_jours_absence
##   <chr>                <dbl>
## 1 Female                 256
## 2 Male                   272
```

La sortie nous dit qu'au total, parmi toutes les femmes de l'échantillon, 256 jours de travail ont été manqués en raison de symptômes similaires à ceux du COVID, et parmi tous les hommes, 272 jours.

J'espère que vous voyez maintenant pourquoi `summarize()` est si puissant. En combinaison avec `group_by()`, il vous permet d'obtenir des résumés de vos jeux de données groupés très informatifs avec très peu de lignes de code.

Produire de tels résumés est une partie très importante de la plupart des processus d'analyse de données, cette compétence sera donc probablement utile très prochainement !

`summarize()` produit des "Tableaux croisés dynamiques"

Les jeux de données récapitulatifs créés par `summarize()` sont souvent appelés des tableaux croisés dynamiques dans le contexte des logiciels de tableur comme Microsoft Excel.

Utilisez `group_by()` et `summarize()` pour obtenir le poids moyen (kg) en fonction du statut de fumeur dans le jeu de données `yao`. Nommez la colonne de poids moyen `poids_moyen`

Le jeu de données de sortie doit ressembler à ceci :

fumeur	poids_moyen
Ex-fumeur	
Non-fumeur	
Fumeur	
NA	


```
_selon_statut_fumeur <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

Utilisez `group_by()`, `summarize()` et les fonctions de statistiques récapitulatives pertinentes pour obtenir les tailles minimum et maximum pour chaque sexe dans le jeu de données `yao`.

Votre sortie doit être un jeu de données avec trois colonnes nommées comme indiqué ci-dessous :

sexe	taille_min_cm	taille_max_cm
Female		
Male		

```
ax_taille_selon_sexe <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

Utilisez `group_by()`, `summarize()`, et la fonction `sum()` pour calculer le nombre total de jours alités (de la variable `jours_alite`) rapportés par les répondants de chaque sexe.

Votre sortie doit être un jeu de données avec deux colonnes nommées comme indiqué ci-dessous :

sexe	total_jours_alite
Female	
Male	

```
_jours_alite <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

Regroupement par plusieurs variables (groupement imbriqué)

Il est possible de regrouper un jeu de données par plus d'une variable. Ceci est parfois appelé "groupement imbriqué".

Prenons un exemple. Supposons que vous voulez connaître l'âge moyen des hommes et des femmes *dans chaque quartier* (plutôt que l'âge moyen de *toutes* les femmes), vous pourriez mettre à la fois `sexe` et `quartier` dans l'instruction `group_by()` :

```
_by(sexe, quartier) %>%
ize(age_moyen = mean(age))
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 18 × 3
## # Groups:   sexe [2]
##    sexe   quartier     age_moyen
##    <chr>  <chr>            <dbl>
##  1 Female Briqueterie       31.6
##  2 Female Carriere          28.2
##  3 Female Cité Verte        31.8
##  4 Female Ekoudou           29.3
##  5 Female Messa             30.2
##  6 Female Mokolo            28.0
##  7 Female Nkomkana          33.0
##  8 Female Tsinga            30.6
##  9 Female Tsinga Oliga      24.3
## 10 Male   Briqueterie       33.7
## 11 Male   Carriere          30.0
## 12 Male   Cité Verte        27.0
## 13 Male   Ekoudou           25.2
## 14 Male   Messa             23.9
## 15 Male   Mokolo            30.5
## 16 Male   Nkomkana          29.8
## 17 Male   Tsinga            28.8
## 18 Male   Tsinga Oliga      24.3
```

À partir de ce jeu de données de sortie, vous pouvez voir que, par exemple, les femmes de Briqueterie ont un âge moyen de 31,6 ans, tandis que les hommes de Briqueterie ont un âge moyen de 33,7 ans.

L'ordre des colonnes listées dans `group_by()` est interchangeable. Donc, si vous exécutez `group_by(quartier, sexe)` au lieu de `group_by(sexe, quartier)`, vous obtiendrez le même résultat, bien qu'il soit ordonné différemment :

```
_by(quartier, sexe) %>%
ize(age_moyen = mean(age))
```

```
## `summarise()` has grouped output by
## 'quartier'. You can override using
## the `.groups` argument.
```

```
## # A tibble: 18 × 3
## # Groups:   quartier [9]
##    quartier      sexe   age_moyen
##    <chr>         <chr>      <dbl>
##  1 Briqueterie   Female      31.6
##  2 Briqueterie   Male        33.7
##  3 Carriere      Female      28.2
##  4 Carriere      Male        30.0
##  5 Cité Verte    Female      31.8
##  6 Cité Verte    Male        27.0
##  7 Ekoudou       Female      29.3
##  8 Ekoudou       Male        25.2
##  9 Messa         Female      30.2
## 10 Messa         Male        23.9
## 11 Mokolo        Female      28.0
## 12 Mokolo        Male        30.5
## 13 Nkomkana      Female      33.0
## 14 Nkomkana      Male        29.8
## 15 Tsinga        Female      30.6
## 16 Tsinga        Male        28.8
## 17 Tsinga Oliga  Female      24.3
## 18 Tsinga Oliga  Male        24.3
```

Maintenant, l'ordre des colonnes est différent : `quartier` est la première colonne, et `sexe`est la deuxième. Et l'ordre des lignes est également différent : les lignes sont d'abord ordonnées par `quartier`, puis ordonnées par `sexe` à l'intérieur de chaque quartier.

Mais les statistiques de résumé sont les mêmes. Par exemple, vous pouvez à nouveau voir que les femmes de Briqueterie ont un âge moyen de 31,6 ans, tandis que les hommes de Briqueterie ont un âge moyen de 33,7 ans.

En utilisant le jeu de données `yao`, groupez vos données par sexe (`sexe`) et traitements (`combinaisons_traitement`) en utilisant `group_by`. Ensuite, en utilisant `summarize()` et la fonction de statistique récapitulative appropriée, calculez le poids moyen (`poids_kg`) pour chaque groupe.

Votre sortie doit être un jeu de données avec trois colonnes nommées comme indiqué ci-dessous :

sexe	combinaisons_traitement	poids_moyen_kg


```
_selon_sexe_traitement <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

En utilisant le jeu de données `yao`, groupez vos données par catégorie d'âge (`cat_age_3`), genre (`sexe`), et résultats d'IgG (`resultat_igg`) en utilisant `group_by`. Ensuite, en utilisant `summarize()` et la fonction de statistique récapitulative appropriée, calculez le nombre moyen de jours alités (`moyenne_jours_alite`) pour chaque groupe.

Votre sortie doit être un jeu de données avec quatre colonnes nommées comme indiqué ci-dessous :

cat_age_3	sexe	resultat_igg	moyenne_jours_alite

```
_alite_age_sex_igg <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

Dégroupement avec `dplyr::ungroup()` (pourquoi et comment)

Quand vous utilisez `group_by()` pour plus d'une variable avant d'utiliser `summarize()`, le jeu de données de sortie reste groupé. Ce regroupement persistant peut avoir des effets indésirables en aval, vous devrez donc parfois utiliser `dplyr::ungroup()` pour dégrouper les données avant de faire une analyse plus poussée.

Pour comprendre *pourquoi* vous devriez utiliser `ungroup()` sur les données, considérez d'abord l'exemple suivant, où nous ne regroupons qu'une seule variable avant de calculer une statistique récapitulative :

```
_by(sexe) %>%
ize(mean_age = mean(age))
```

```
## # A tibble: 2 × 2
##   sexe   mean_age
##   <chr>     <dbl>
```

```
## 1 Female     29.5
## 2 Male       28.4
```

Les données sont produites comme un jeu de données normal ; il n'est pas groupé. Vous pouvez le voir parce qu'il n'y a pas d'information sur les groupes dans l'en-tête.

Mais considérez maintenant quand vous regroupez par deux variables avant de calculer une statistique récapitulative :

```
_by(sexe, quartier) %>%
:ize(mean_age = mean(age))
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 18 × 3
## # Groups:   sexe [2]
##    sexe   quartier     mean_age
##    <chr>  <chr>           <dbl>
##  1 Female Briqueterie      31.6
##  2 Female Carriere         28.2
##  3 Female Cité Verte       31.8
##  4 Female Ekoudou          29.3
##  5 Female Messa            30.2
##  6 Female Mokolo           28.0
##  7 Female Nkomkana         33.0
##  8 Female Tsinga           30.6
##  9 Female Tsinga Oliga     24.3
## 10 Male   Briqueterie      33.7
## 11 Male   Carriere         30.0
## 12 Male   Cité Verte       27.0
## 13 Male   Ekoudou          25.2
## 14 Male   Messa            23.9
## 15 Male   Mokolo           30.5
## 16 Male   Nkomkana         29.8
## 17 Male   Tsinga           28.8
## 18 Male   Tsinga Oliga     24.3
```

Maintenant, l'en-tête vous indique que les données sont toujours groupées par la première variable dans `group_by()`, ici sexe :

```
  # A tibble: 18 × 3
👉# Groups:   sexe [2]👈
```

Quelle est l'implication de ce regroupement persistant dans le jeu de données ? Cela signifie que le jeu de données peut montrer un comportement qui semble étrange

lorsque vous essayez d'appliquer certaines fonctions {dplyr} dessus.

Par exemple, si vous essayez de `select()` une seule variable, peut-être la variable `mean_age`, vous devriez normalement pouvoir utiliser `select(mean_age)` :

```
_by(sexe, quartier) %>%
rize(mean_age = mean(age)) %>%
t(mean_age) # ne fonctionne pas comme prévu
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
## Adding missing grouping variables:
## `sexe`
```

```
## # A tibble: 18 × 2
## # Groups:   sexe [2]
##    sexe   mean_age
##    <chr>     <dbl>
##  1 Female     31.6
##  2 Female     28.2
##  3 Female     31.8
##  4 Female     29.3
##  5 Female     30.2
##  6 Female     28.0
##  7 Female     33.0
##  8 Female     30.6
##  9 Female     24.3
## 10 Male       33.7
## 11 Male       30.0
## 12 Male       27.0
## 13 Male       25.2
## 14 Male       23.9
## 15 Male       30.5
## 16 Male       29.8
## 17 Male       28.8
## 18 Male       24.3
```

Mais comme vous pouvez le voir, la variable groupée, `sex`, est *toujours* sélectionnée, même si nous n'avons demandé que `mean_age` dans l'instruction `select()`.

C'est l'un des nombreux exemples de comportements uniques des jeux de données groupés. D'autres verbes dplyr comme `filter()`, `mutate()` et `arrange()` agissent également de manière spéciale sur les données groupées. Nous aborderons cela en détail dans une leçon future.

Vous savez donc maintenant *pourquoi* vous devriez dégrouper les données lorsque vous n'en avez plus besoin. Voyons maintenant *comment* dégrouper les données.

C’est assez simple : il suffit d’ajouter la fonction `ungroup()` à votre chaîne de pipe. Par exemple :

```
_by(sexe, quartier) %>%
ize(mean_age = mean(age)) %>%
up()
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 18 × 3
##    sexe   quartier     mean_age
##    <chr>  <chr>           <dbl>
##  1 Female Briqueterie      31.6
##  2 Female Carriere         28.2
##  3 Female Cité Verte       31.8
##  4 Female Ekoudou          29.3
##  5 Female Messa            30.2
##  6 Female Mokolo           28.0
##  7 Female Nkomkana         33.0
##  8 Female Tsinga           30.6
##  9 Female Tsinga Oliga     24.3
## 10 Male   Briqueterie      33.7
## 11 Male   Carriere         30.0
## 12 Male   Cité Verte       27.0
## 13 Male   Ekoudou          25.2
## 14 Male   Messa            23.9
## 15 Male   Mokolo           30.5
## 16 Male   Nkomkana         29.8
## 17 Male   Tsinga           28.8
## 18 Male   Tsinga Oliga     24.3
```

Maintenant que le jeu de données est dégroupé, il se comportera à nouveau comme un jeu de données normal. Par exemple, vous pouvez `select()` n’importe quelle colonne(s) que vous voulez ; vous n’aurez pas certaines colonnes indésirables qui vous suivent :

```
_by(sexe, quartier) %>%
ize(mean_age = mean(age)) %>%
up() %>%
(mean_age)
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 18 × 1
##    mean_age
##       <dbl>
##  1     31.6
##  2     28.2
##  3     31.8
##  4     29.3
##  5     30.2
##  6     28.0
##  7     33.0
##  8     30.6
##  9     24.3
## 10     33.7
## 11     30.0
## 12     27.0
## 13     25.2
## 14     23.9
## 15     30.5
## 16     29.8
## 17     28.8
## 18     24.3
```

Comptage des lignes

> Vous pouvez faire beaucoup de science des données en *comptant* simplement et occasionnellement en *divisant.* - Hadley Wickham, Scientifique Senior chez RStudio

Une tâche courante de statistique récapitulative des données est de compter combien d'observations (lignes) il y a pour chaque groupe. Vous pouvez y parvenir avec la fonction spéciale `n()` de {dplyr}, qui est spécifiquement conçue pour être utilisée dans `summarise()`.

Par exemple, si vous voulez compter combien d'individus se trouvent dans chaque groupe de quartier, vous exécuteriez :

```
by(quartier) %>%
ize(nombre = n())
```

```
## # A tibble: 9 × 2
##   quartier     nombre
##   <chr>         <int>
## 1 Briqueterie     106
## 2 Carriere        236
## 3 Cité Verte       72
## 4 Ekoudou         190
```

```
## 5 Messa            48
## 6 Mokolo           96
## 7 Nkomkana         75
## 8 Tsinga           81
## 9 Tsinga Oliga     67
```

Comme vous pouvez le voir, la fonction `n()` ne nécessite aucun argument. Elle "connait son travail" dans le jeu de données !

Bien sûr, vous pouvez inclure d'autres statistiques récapitulatives dans le même appel `summarize()`. Par exemple, ci-dessous, nous calculons également l'âge moyen par quartier.

```
by(quartier) %>%
ize(nombre = n(),
    mean_age = mean(age))
```

```
## # A tibble: 9 × 3
##   quartier     nombre mean_age
##   <chr>         <int>    <dbl>
## 1 Briqueterie     106     32.5
## 2 Carriere        236     28.9
## 3 Cité Verte       72     29.9
## 4 Ekoudou         190     27.6
## 5 Messa            48     27.3
## 6 Mokolo           96     29.1
## 7 Nkomkana         75     31.7
## 8 Tsinga           81     29.7
## 9 Tsinga Oliga     67     24.3
```

Groupez votre jeu de données `yao` par l'occupation des répondants (`occupation`) et utilisez `summarize()` pour créer des colonnes qui montrent :

- combien d'individus il y a avec chaque occupation (pensez à la fonction `n()`)
- le nombre moyen de jours de travail manqués (`moyenne_age`) par ceux ayant cette occupation

Votre sortie doit être un jeu de données avec trois colonnes nommées comme indiqué ci-dessous :

occupation	nombre	moyenne_age


```
e_occupation <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

Compter les lignes qui répondent à une condition

Plutôt que de compter *toutes* les lignes comme ci-dessus, il est parfois plus utile de compter seulement les lignes qui répondent à des conditions spécifiques. Cela peut être fait facilement en plaçant les conditions requises dans la fonction `sum()`.

Par exemple, pour compter le nombre de personnes de moins de 18 ans dans chaque quartier, vous placez la condition `age < 18` à l'intérieur de `sum()` :

```
_by(quartier) %>%
rize(nombre_inferieur_18 = sum(age < 18))
```

```
## # A tibble: 9 × 2
##   quartier     nombre_inferieur_18
##   <chr>                      <int>
## 1 Briqueterie                   28
## 2 Carriere                      58
## 3 Cité Verte                    19
## 4 Ekoudou                       66
## 5 Messa                         18
## 6 Mokolo                        32
## 7 Nkomkana                      22
## 8 Tsinga                        23
## 9 Tsinga Oliga                  25
```

De même, pour compter le nombre de personnes ayant un doctorat dans chaque quartier, vous placez la condition `edu_haute == "Doctorate"` à l'intérieur de `sum()` :

```
_by(quartier) %>%
rize(nombre_avec_doctorates = sum(edu_haute == "Doctorate"))
```

```
## # A tibble: 9 × 2
##   quartier     nombre_avec_doctorates
##   <chr>                         <int>
## 1 Briqueterie                       2
## 2 Carriere                          1
## 3 Cité Verte                        1
## 4 Ekoudou                           1
## 5 Messa                             2
## 6 Mokolo                            0
## 7 Nkomkana                          4
```

```
## 8 Tsinga                          3
## 9 Tsinga Oliga                    3
```

Sous le capot : compter avec des conditions

Pourquoi pouvez-vous utiliser `sum()`, qui est censé ajouter des nombres, sur une condition comme `edu_haute == "Doctorate"` ?

Utiliser `sum()` sur une condition fonctionne parce que la condition évalue aux valeurs booléennes `TRUE` et `FALSE`. Et ces valeurs booléennes sont traitées comme des nombres (où `TRUE` est égal à 1 et `FALSE` est égal à 0), et les nombres peuvent, bien sûr, être sommés.

Le code ci-dessous démontre ce qui se passe sous le capot de manière étape par étape. Exécutez-le et voyez si vous pouvez suivre.

CHALLENGE

```
_condition_sums <- yao %>%
(edu_haute) %>%
(avec_doctorate = edu_haute == "Doctorate") %>%
(numerique_avec_doctorate = as.numeric(avec_doctorate))

_condition_sums
```

```
## # A tibble: 971 × 3
##    edu_haute  avec_doctorate
##    <chr>      <lgl>
##  1 Secondary  FALSE
##  2 University FALSE
##  3 University FALSE
##  4 Secondary  FALSE
##  5 Primary    FALSE
##  6 Secondary  FALSE
##  7 Secondary  FALSE
##  8 Doctorate  TRUE
##  9 Secondary  FALSE
## 10 Secondary  FALSE
##    numerique_avec_doctorate
##                       <dbl>
##  1                        0
##  2                        0
##  3                        0
##  4                        0
##  5                        0
##  6                        0
##  7                        0
##  8                        1
##  9                        0
```

```
## 10                          0
## # ℹ 961 more rows
```

CHALLENGE

Les valeurs numériques peuvent ensuite être ajoutées pour produire un décompte des lignes remplissant la condition `edu_haute == "Doctorate"` :

```
condition_sums %>%
ize(nombre_avec_doctorate = sum(numerique_avec_doctorate))
```

```
## # A tibble: 1 × 1
##   nombre_avec_doctorate
##                   <dbl>
## 1                    17
```

Pour une illustration finale du comptage avec des conditions, considérez la variable `combinaisons_traitement`, qui liste les traitements reçus par les personnes présentant des symptômes similaires à ceux du COVID. Les personnes qui n'ont reçu aucun traitement ont une valeur `NA` :

```
(combinaisons_traitement)
```

```
## # A tibble: 971 × 1
##    combinaisons_traitement
##    <chr>
##  1 Paracetamol
##  2 <NA>
##  3 <NA>
##  4 Antibiotics
##  5 <NA>
##  6 Paracetamol--Antibiotics
##  7 Traditional meds.
##  8 Paracetamol
##  9 Paracetamol--Traditional meds.
## 10 <NA>
## # ℹ 961 more rows
```

Si vous voulez compter le nombre de personnes qui n'ont reçu *aucun traitement*, vous additionneriez celles qui répondent à la condition `is.na(combinaisons_traitement)` :

```
_by(quartier) %>%
rize(traitement_inconnu = sum(is.na(combinaisons_traitement)))
```

```
## # A tibble: 9 × 2
##   quartier     traitement_inconnu
##   <chr>                     <int>
## 1 Briqueterie                  82
## 2 Carriere                    192
## 3 Cité Verte                   46
## 4 Ekoudou                     133
## 5 Messa                        35
## 6 Mokolo                       65
## 7 Nkomkana                     53
## 8 Tsinga                       56
## 9 Tsinga Oliga                 47
```

Ce sont les personnes ayant des valeurs `NA` pour la colonne `combinaisons_traitement`.

Pour compter les personnes qui *ont* reçu un traitement, vous pouvez simplement nier la fonction `is.na()` avec `!` :

```
 group_by(quartier) %>%
rize(traitment_connu = sum(!is.na(combinaisons_traitement)))
```

```
## # A tibble: 9 × 2
##   quartier     traitment_connu
##   <chr>                  <int>
## 1 Briqueterie               24
## 2 Carriere                  44
## 3 Cité Verte                26
## 4 Ekoudou                   57
## 5 Messa                     13
## 6 Mokolo                    31
## 7 Nkomkana                  22
## 8 Tsinga                    25
## 9 Tsinga Oliga              20
```

dplyr::count()

La fonction `dplyr::count()` regroupe plusieurs choses en une seule ligne de code conviviale pour vous aider à trouver les comptages d'observations par groupe.

Utilisons `dplyr::count()` sur notre variable `occupation` :

```
(occupation)
```

```
## # A tibble: 28 × 2
##    occupation
##    <chr>
##  1 Farmer
##  2 Farmer--Other
##  3 Home-maker
##  4 Home-maker--Farmer
##  5 Home-maker--Informal worker
##  6 Home-maker--Informal worker--Farmer
##  7 Home-maker--Trader
##  8 Informal worker
##  9 Informal worker--Other
## 10 Informal worker--Trader
##        n
##    <int>
##  1     5
##  2     1
##  3    65
##  4     2
##  5     3
##  6     1
##  7     3
##  8   189
##  9     2
## 10     4
## # ℹ 18 more rows
```

Notez que c'est la même sortie que :

```
by(occupation) %>%
ize(n = n())
```

```
## # A tibble: 28 × 2
##    occupation
##    <chr>
##  1 Farmer
##  2 Farmer--Other
##  3 Home-maker
##  4 Home-maker--Farmer
##  5 Home-maker--Informal worker
##  6 Home-maker--Informal worker--Farmer
##  7 Home-maker--Trader
##  8 Informal worker
##  9 Informal worker--Other
## 10 Informal worker--Trader
##        n
##    <int>
##  1     5
##  2     1
##  3    65
##  4     2
```

```
##  5     3
##  6     1
##  7     3
##  8   189
##  9     2
## 10     4
## # ℹ 18 more rows
```

Vous pouvez également appliquer `dplyr::count()` de manière imbriquée :

```
(sexe, occupation)
```

```
## # A tibble: 40 × 3
##    sexe
##    <chr>
##  1 Female
##  2 Female
##  3 Female
##  4 Female
##  5 Female
##  6 Female
##  7 Female
##  8 Female
##  9 Female
## 10 Female
##    occupation                          n
##    <chr>                           <int>
##  1 Farmer                              3
##  2 Home-maker                         65
##  3 Home-maker--Farmer                  2
##  4 Home-maker--Informal worker         3
##  5 Home-maker--Informal worker-…       1
##  6 Home-maker--Trader                  3
##  7 Informal worker                    77
##  8 Informal worker--Trader             1
##  9 No response                         8
## 10 Other                               6
## # ℹ 30 more rows
```

Le verbe `count()` vous donne des informations clés sur votre ensemble de données de manière très rapide. Regardons nos résultats IgG stratifiés par catégorie d'âge et par sexe en une seule ligne de code.

En utilisant le jeu de données `yao`, comptez les différentes combinaisons de genre (`sex`), de catégories d'âge (`cat_age_3`) et de résultats IgG (`resultat_igg`).

Votre sortie doit être un jeu de données avec quatre colonnes nommées comme indiqué ci-dessous :

sexe	cat_age_3	resultat_igg	n

```
e_resultats <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

En utilisant le jeu de données `yao`, comptez les différentes combinaisons de catégories d'âge (`cat_age_3`) et de nombre de jours alités (`total_jours_alite`).

Votre sortie doit être un jeu de données avec trois colonnes nommées comme indiqué ci-dessous :

cat_age_3	total_jours_alite	n

```
e_jours_alite_age <-
>%
/EZ_VOTRE_RÉPONSE_ICI"
```

L'inconvénient de `count()` est qu'il ne peut vous donner qu'une seule statistique récapitulative dans le jeu de données. Lorsque vous utilisez `summarize()` et `n()`, vous pouvez inclure plusieurs statistiques récapitulatives. Par exemple :

```
by(sexe, quartier) %>%
ize(count = n(),
    median_age = median(age))
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 18 × 4
## # Groups:   sexe [2]
##    sexe   quartier     count
##    <chr>  <chr>        <int>
##  1 Female Briqueterie     61
##  2 Female Carriere       140
##  3 Female Cité Verte      44
##  4 Female Ekoudou        110
```

```
##  5 Female Messa           26
##  6 Female Mokolo          53
##  7 Female Nkomkana        43
##  8 Female Tsinga          42
##  9 Female Tsinga Oliga    30
## 10 Male   Briqueterie     45
## 11 Male   Carriere        96
## 12 Male   Cité Verte      28
## 13 Male   Ekoudou         80
## 14 Male   Messa           22
## 15 Male   Mokolo          43
## 16 Male   Nkomkana        32
## 17 Male   Tsinga          39
## 18 Male   Tsinga Oliga    37
##    median_age
##         <dbl>
##  1       28
##  2       25.5
##  3       28
##  4       26.5
##  5       27.5
##  6       23
##  7       28
##  8       29
##  9       23.5
## 10       28
## 11       27
## 12       22.5
## 13       21.5
## 14       24.5
## 15       32
## 16       27
## 17       27
## 18       21
```

Mais `count()` ne peut produire que des comptages :

```
by(sexe, quartier) %>%
()
```

```
## # A tibble: 18 × 3
## # Groups:   sexe, quartier [18]
##    sexe   quartier         n
##    <chr>  <chr>        <int>
##  1 Female Briqueterie     61
##  2 Female Carriere       140
##  3 Female Cité Verte      44
##  4 Female Ekoudou        110
##  5 Female Messa           26
##  6 Female Mokolo          53
##  7 Female Nkomkana        43
##  8 Female Tsinga          42
##  9 Female Tsinga Oliga    30
```

```
## 10 Male   Briqueterie     45
## 11 Male   Carriere        96
## 12 Male   Cité Verte      28
## 13 Male   Ekoudou         80
## 14 Male   Messa           22
## 15 Male   Mokolo          43
## 16 Male   Nkomkana        32
## 17 Male   Tsinga          39
## 18 Male   Tsinga Oliga    37
```

~~Inclure les~~ combinaisons manquantes dans les statistiques récapitulatives

Lorsque vous utilisez `group_by()` et `summarize()` sur plusieurs variables, vous obtenez une statistique récapitulative pour chaque combinaison unique des variables groupées. Par exemple, considérez le code et la sortie ci-dessous, qui comptent le nombre d'individus dans chaque groupe d'âge et de sexe :

```
_by(sexe, cat_age_3) %>%
rise(nombre_d_individus = n())
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 6 × 3
## # Groups:   sexe [2]
##   sexe   cat_age_3 nombre_d_individus
##   <chr>  <chr>                  <int>
## 1 Female Adult                    368
## 2 Female Child                    155
## 3 Female Senior                    26
## 4 Male   Adult                    267
## 5 Male   Child                    136
## 6 Male   Senior                    19
```

Dans le jeu de données de sortie, il y a une ligne pour chaque combinaison de sexe et de groupe d'âge (Femme—Adulte, Femme—Enfant, etc.).

Mais que se passe-t-il si l'une de ces combinaisons n'est pas présente dans les données ?

Créons un exemple artificiel pour observer cela. Avec le code ci-dessous, nous supprimons artificiellement tous les enfants de sexe masculin du jeu de données `yao`

:

```
nale_children <-
>%
r(!(sexe == "Male" & cat_age_3 == "Child"))
```

Maintenant, si vous exécutez le même appel `group_by()` et `summarize()` sur `yao_no_male_children`, vous remarquerez la combinaison manquante :

```
nale_children %>%
_by(sexe, cat_age_3) %>%
rise(number_of_individuals = n())
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 5 × 3
## # Groups:   sexe [2]
##   sexe   cat_age_3
##   <chr>  <chr>
## 1 Female Adult
## 2 Female Child
## 3 Female Senior
## 4 Male   Adult
## 5 Male   Senior
##   number_of_individuals
##                   <int>
## 1                   368
## 2                   155
## 3                    26
## 4                   267
## 5                    19
```

En effet, il n'y a pas de ligne pour les enfants de sexe masculin.

Mais parfois, il est utile d'inclure ces combinaisons manquantes dans le jeu de données de sortie, avec une valeur `NA` ou 0 pour la statistique récapitulative.

Pour ce faire, vous pouvez exécuter le code suivant à la place :

```
nale_children %>%
vertir les variables en facteurs
e(sexe = as.factor(sexe),
  cat_age_3 = as.factor(cat_age_3)) %>%
ez l'argument .drop = FALSE
_by(sexe, cat_age_3, .drop = FALSE) %>%
rise(number_of_individuals = n())
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 6 × 3
## # Groups:   sexe [2]
##   sexe   cat_age_3
##   <fct>  <fct>
## 1 Female Adult
## 2 Female Child
## 3 Female Senior
## 4 Male   Adult
## 5 Male   Child
## 6 Male   Senior
##   number_of_individuals
##                   <int>
## 1                   368
## 2                   155
## 3                    26
## 4                   267
## 5                     0
## 6                    19
```

Que fait ce code ?

- D'abord, il convertit les variables de regroupement en facteurs avec `as.factor()` (dans un appel à `mutate()`)
- Ensuite, il utilise l'argument `.drop = FALSE` dans la fonction `group_by()` pour éviter de supprimer les combinaisons manquantes.

Vous avez maintenant un compte clair de `0` pour le nombre d'enfants de sexe masculin !

Voyons un autre exemple, cette fois sans modifier artificiellement nos données.

Le code ci-dessous calcule l'âge moyen par sexe et par niveau d'éducation :

```
_by(sexe, edu_haute) %>%
rise(mean_age = mean(age))
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 13 × 3
## # Groups:   sexe [2]
##    sexe   edu_haute
##    <chr>  <chr>
##  1 Female Doctorate
##  2 Female No formal instruction
##  3 Female No response
##  4 Female Primary
##  5 Female Secondary
##  6 Female University
##  7 Male   Doctorate
##  8 Male   No formal instruction
##  9 Male   No response
## 10 Male   Other
## 11 Male   Primary
## 12 Male   Secondary
## 13 Male   University
##    mean_age
##       <dbl>
##  1     28
##  2     45.6
##  3     35
##  4     26.8
##  5     28.8
##  6     31.5
##  7     42.2
##  8     37.9
##  9     22
## 10      5.5
## 11     22.9
## 12     29.4
## 13     31.9
```

Remarquez que dans le jeu de données de sortie, il y a 7 lignes pour les hommes mais seulement 6 lignes pour les femmes, car aucune femme n'a répondu "Autre" à la question sur le niveau d'éducation le plus élevé.

Si vous voulez néanmoins inclure la ligne "Femme—Autre" dans le jeu de données de sortie, vous exécuteriez :

```
e(sexe = as.factor(sexe),
  edu_haute = as.factor(edu_haute)) %>%
 by(sexe, edu_haute, .drop = FALSE) %>%
rise(mean_age = mean(age))
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

```
## # A tibble: 14 × 3
## # Groups:   sexe [2]
##    sexe   edu_haute
##    <fct>  <fct>
##  1 Female Doctorate
##  2 Female No formal instruction
##  3 Female No response
##  4 Female Other
##  5 Female Primary
##  6 Female Secondary
##  7 Female University
##  8 Male   Doctorate
##  9 Male   No formal instruction
## 10 Male   No response
## 11 Male   Other
## 12 Male   Primary
## 13 Male   Secondary
## 14 Male   University
##    mean_age
##       <dbl>
##  1     28
##  2     45.6
##  3     35
##  4    NaN
##  5     26.8
##  6     28.8
##  7     31.5
##  8     42.2
##  9     37.9
## 10     22
## 11      5.5
## 12     22.9
## 13     29.4
## 14     31.9
```

En utilisant le jeu de données `yao`, calculons l'âge médian en regroupant par quartier, catégorie d'âge et sexe.

Notez que nous voulons toutes les combinaisons possibles de ces trois variables (pas seulement celles présentes dans nos données).

Faites attention à deux impératifs de préparation des données !

- convertissez vos variables de regroupement en facteurs au préalable en utilisant `mutate()`
- calculez votre statistique, la médiane, tout en supprimant les valeurs `NA`.

PRACTICE

(in RMD)

Votre sortie doit être un jeu de données avec quatre colonnes nommées comme indiqué ci-dessous :

quartier	cat_age_3	sexe	median_age

```
ne_quartier_age_sexe <-
>%
VEZ_VOTRE_RÉPONSE_ICI"
```

Pourquoi inclure les combinaisons manquantes ?

Ci-dessus, nous avons mentionné que l'inclusion de combinaisons manquantes est souvent utile dans le processus d'analyse de données. Voyons un cas d'utilisation : la conception des graphiques avec {ggplot}. Si vous n'avez pas encore appris {ggplot}, ce n'est pas grave, concentrez-vous simplement sur les sorties de graphique.

SIDE NOTE

Pour réaliser un diagramme à barres composé avec les comptes d'âge-sexe de `yao_no_male_children`, vous pourriez exécuter :

```
nale_children %>%
_by(sexe, cat_age_3) %>%
rise(nombre_d_individus = n()) %>%
up() %>%

nsmettre la sortie à ggplot
() +
col(aes(x = sexe, y = nombre_d_individus, fill = cat_age_3),
    position = "dodge")
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

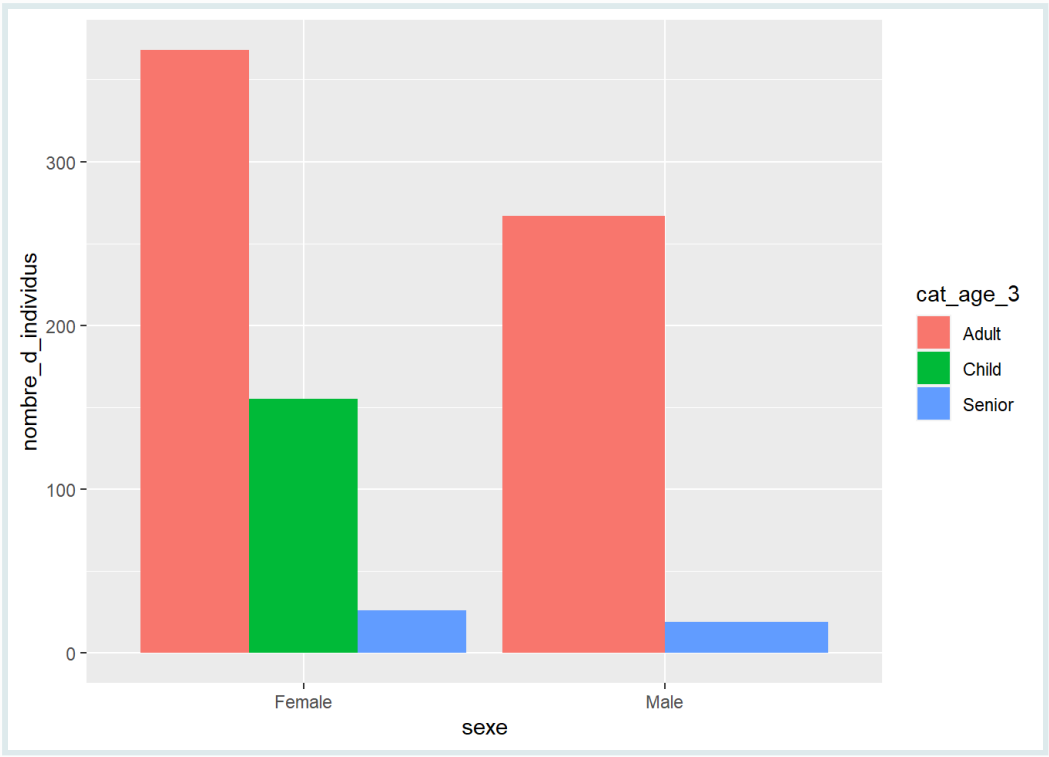

SIDE NOTE

Pas très élégant ! Idéalement, il devrait y avoir un espace vide indiquant 0 pour le nombre d'enfants de sexe masculin.

Si vous mettez en œuvre la procédure pour inclure les combinaisons manquantes, vous obtenez un diagramme à barres composé plus naturel, avec un espace vide pour les enfants de sexe masculin :

```
hale_children %>%
e(sexe = as.factor(sexe),
  cat_age_3 = as.factor(cat_age_3)) %>%
_by(sexe, cat_age_3, .drop = FALSE) %>%
rise(nombre_d_individus = n()) %>%
up() %>%

nsmettre la sortie à ggplot
t() +
col(aes(x = sexe, y = nombre_d_individus, fill = cat_age_3),
    position = "dodge")
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

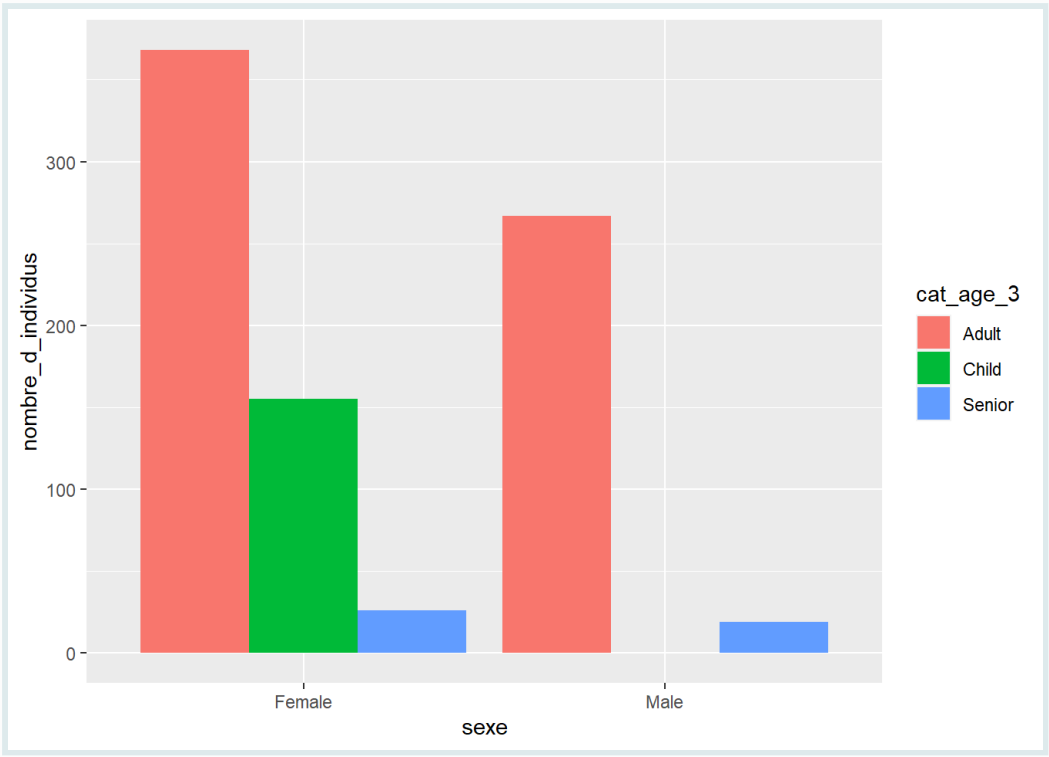

SIDE NOTE

Beaucoup mieux !

Au fait, cette sortie peut être légèrement améliorée en définissant les niveaux de facteur pour l'âge dans leur ordre croissant correct : d'abord "Enfant", puis "Adulte" puis "Senior" :

```
hale_children %>%
e(sexe = as.factor(sexe),
  cat_age_3 = factor(cat_age_3,
                     levels = c("Enfant",
                                "Adulte",
                                "Senior"))) %>%
_by(sexe, cat_age_3, .drop = FALSE) %>%
rise(nombre_d_individus = n()) %>%
up() %>%

nsmettre la sortie à ggplot
t() +
col(aes(x = sexe, y = nombre_d_individus, fill = cat_age_3),
    position = "dodge")
```

```
## `summarise()` has grouped output by
## 'sexe'. You can override using the
## `.groups` argument.
```

SIDE NOTE

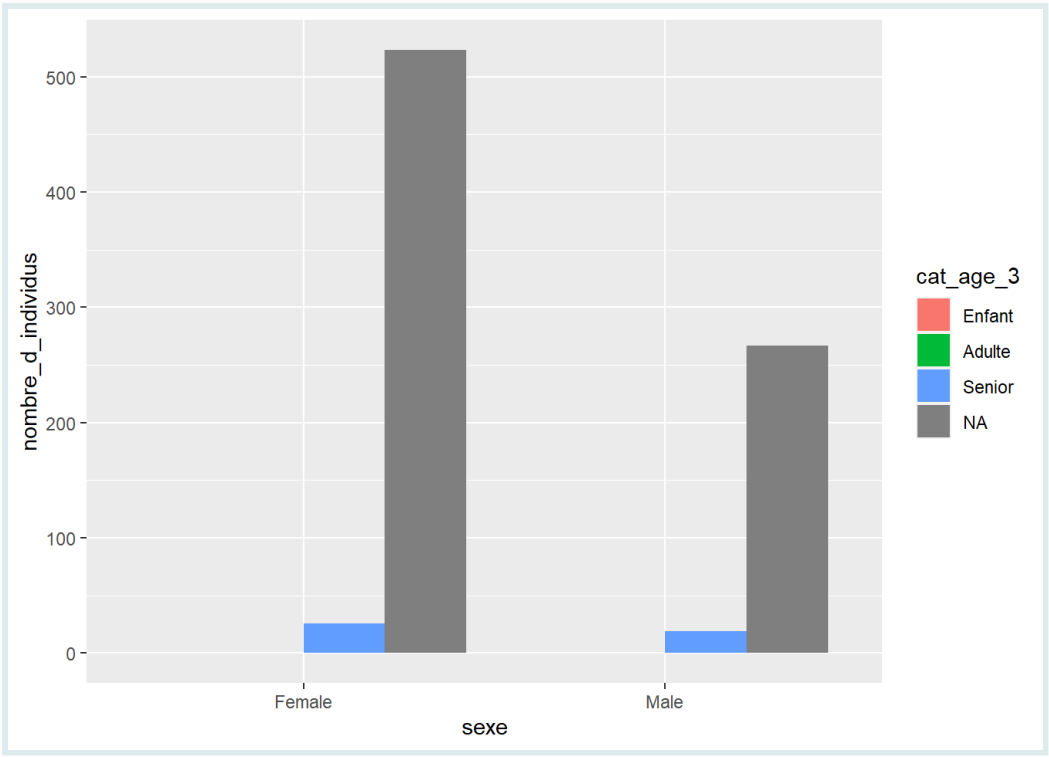

Conclusion

Vous avez maintenant vu comment obtenir des statistiques récapitulatives rapides à partir de vos données, soit pour l'exploration de données, soit pour une présentation ou une visualisation de données supplémentaires.

De plus, vous avez découvert l'une des merveilles de {dplyr}, la possibilité de grouper vos données à l'aide de `group_by()`.

`group_by()` combiné avec `summarize()` est l'une des manipulations de regroupement les plus courantes.

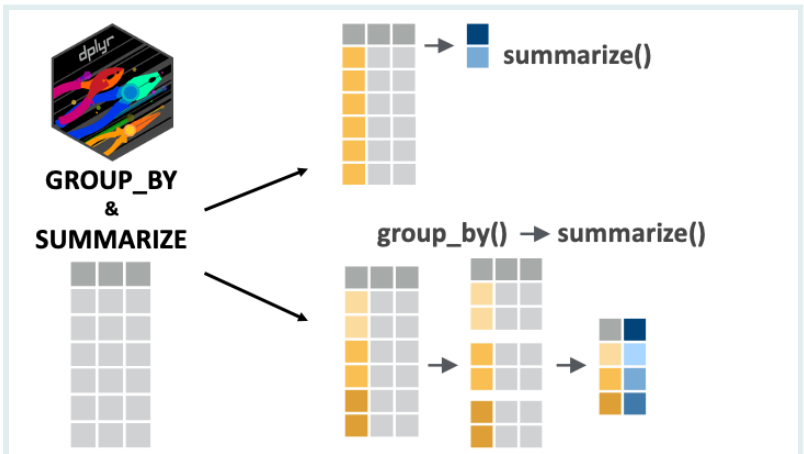

Fig: summarize() et son utilisation combinée avec group_by().

Cependant, vous pouvez également combiner `group_by()` avec de nombreux autres verbes {dplyr} : c'est ce que nous couvrirons dans notre prochaine leçon. À bientôt !

Contributeurs

Les membres suivants de l'équipe ont contribué à cette leçon:

LAURE VANCAUWENBERGHE

Data analyst, the GRAPH Network
A firm believer in science for good, striving to ally programming, health and education

ANDREE VALLE CAMPOS

R Developer and Instructor, the GRAPH Network
Motivated by reproducible science and education

KENE DAVID NWOSU

Data analyst, the GRAPH Network
Passionate about world improvement

SABINA RODRIGUEZ VELÁSQUEZ

Project Manager and Scientific Collaborator, The GRAPH Network
Infectiously enthusiastic about microbes and Global Health

Merci à Alice Osmaston et Saifeldin Shehata pour leurs commentaires et leur revue.

Références

Certaines informations de cette leçon ont été adaptées des sources suivantes :

- Horst, A. (2022). *Dplyr-learnr*. https://github.com/allisonhorst/dplyr-learnr (Travail original publié en 2020)
- *Group by one or more variables*. (s.d.). Consulté le 21 février 2022, sur https://dplyr.tidyverse.org/reference/group_by.html

- *Summarise each group to fewer rows*. (s.d.). Consulté le 21 février 2022, sur https://dplyr.tidyverse.org/reference/summarize.html

- The Carpentries. (s.d.). *Grouped operations using `dplyr`*. Grouped operations using `dplyr` – Introduction to R/tidyverse for Exploratory Data Analysis. Consulté le 28 juillet 2022, sur https://tavareshugo.github.io/r-intro-tidyverse-gapminder/06-grouped_operations_dplyr/index.html

L'œuvre d'art a été adaptée de :

- Horst, A. (2022). *R & stats illustrations by Allison Horst*. https://github.com/allisonhorst/stats-illustrations (Travail original publié en 2018)