Notes de leçon | Filtrer, modifier et organiser par groupes

January 2024

Introduction

La manipulation de données implique souvent d'appliquer les mêmes opérations séparément à différents groupes au sein des données. Ce motif, parfois appelé "split-apply-combine", est facilement réalisable dans {dplyr} en enchaînant le verbe `group_by()` avec d'autres verbes de manipulation tels que `filter()`, `mutate()` et `arrange()` (que vous avez déjà vus !).

Dans cette leçon, vous deviendrez confiant avec ce type de manipulations groupées.

Commençons.

Objectifs d'apprentissage

1. Vous pouvez utiliser `group_by()` avec `arrange()`, `filter()` et `mutate()` pour effectuer des opérations groupées sur un jeu de données.

Packages

Cette leçon exigera la suite de packages {tidyverse} et le package {here} :

```
ire(pacman)) install.packages("pacman")
p_load(tidyverse, here)
```

Jeux de données

Dans cette leçon, nous utiliserons encore les données de l'enquête sérologique COVID-19 menée à Yaoundé, au Cameroun. Ci-dessous, nous importons les données, créons un petit sous-ensemble du jeu de données, `yao` et un sous-ensemble encore plus petit, `yao_sexe_poids`.

```
csv(here::here('data/fr_yaounde_data.csv'))  %>%
t(sexe, age, cat_age, poids_kg, occupation, resultat_igg, resultat_igm)
```

```
## # A tibble: 5 × 7
##   sexe     age cat_age poids_kg occupation      resultat_igg
##   <chr>  <dbl> <chr>      <dbl> <chr>           <chr>
## 1 Female    45 45 - 64       95 Informal worker Negative
## 2 Male      55 45 - 64       96 Salaried worker Positive
## 3 Male      23 15 - 29       74 Student         Negative
## 4 Female    20 15 - 29       70 Student         Positive
## 5 Female    55 45 - 64       67 Trader--Farmer  Positive
## # ℹ 1 more variable: resultat_igm <chr>
```

```
e_poids <-
>%
t(sexe, poids_kg)

e_poids
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       95
## 2 Male         96
## 3 Male         74
## 4 Female       70
## 5 Female       67
```

Pour les questions pratiques, nous utiliserons également le jeu de données sur la sarcopénie que vous avez déjà vu :

```
ia <- read_csv(here::here('data/fr_sarcopenia_elderly.csv'))

ia
```

```
## # A tibble: 5 × 9
##   numero   age groupe_d_age sexe_homme_1_fe…¹ statut_marital
##    <dbl> <dbl> <chr>                    <dbl> <chr>
## 1      7  60.8 Sixties                      0 married
## 2      8  72.3 Seventies                    1 married
## 3      9  62.6 Sixties                      0 married
## 4     12  72   Seventies                    0 widow
## 5     13  60.1 Sixties                      0 married
## # ℹ abbreviated name: ¹sexe_homme_1_femme_0
## # ℹ 4 more variables: taille_metres <dbl>, …
```

Organisation par groupe

La fonction `arrange()` ordonne les lignes d'un jeu de données par les valeurs des colonnes sélectionnées. Cette fonction est sensible aux groupements uniquement lorsque nous définissons son argument `.by_group` à `TRUE`. Pour illustrer cela, considérons le jeu de données `yao_sexe_poids` :

```
e_poids
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       95
## 2 Male         96
## 3 Male         74
## 4 Female       70
## 5 Female       67
```

Nous pouvons organiser ce jeu de données par poids de cette façon :

```
e_poids %>%
ge(poids_kg)
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       14
## 2 Male         15
## 3 Male         15
## 4 Male         15
## 5 Female       15
```

Comme prévu, les poids les plus faibles ont été placés en haut de la trame de données.

Si nous regroupons d'abord les données, nous pourrions nous attendre à un résultat différent :

```
e_poids %>%
_by(sexe) %>%
ge(poids_kg)
```

```
## # A tibble: 5 × 2
## # Groups:   sexe [2]
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       14
## 2 Male         15
## 3 Male         15
## 4 Male         15
## 5 Female       15
```

Mais comme vous le voyez, l'organisation est toujours la même.

Ce n'est que lorsque nous définissons l'argument `.by_group` à `TRUE` que nous obtenons quelque chose de différent :

```
e_poids %>%
_by(sexe) %>%
ge(poids_kg, .by_group = TRUE)
```

```
## # A tibble: 5 × 2
## # Groups:   sexe [1]
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       14
## 2 Female       15
## 3 Female       16
## 4 Female       16
## 5 Female       18
```

Maintenant, les données sont *d'abord* triées par sexe (toutes les femmes en premier), puis par poids.

`arrange()` peut regrouper automatiquement

En réalité, nous n'avons pas besoin de `group_by()` pour organiser par groupe ; nous pouvons simplement mettre plusieurs variables dans la fonction `arrange()` pour obtenir le même effet.

Ainsi, cette simple commande `arrange()` :

```
e_poids %>%
ge(sexe, poids_kg)
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       14
## 2 Female       15
## 3 Female       16
## 4 Female       16
## 5 Female       18
```

est équivalente à la commande plus complexe `group_by()`, `arrange()` utilisée précédemment :

```
e_poids %>%
_by(sexe) %>%
ge(poids_kg, .by_group = TRUE)
```

La commande `arrange(sexe, poids_kg)` dit à R d'organiser les lignes *d'abord* par sexe, puis par poids.

Évidemment, cette syntaxe, avec juste `arrange()`, et pas de `group_by()` est plus simple, donc vous pouvez vous y tenir.

Rappel

`desc()` **pour l'ordre décroissant**

Rappelez-vous que pour classer *en ordre décroissant*, nous pouvons mettre la variable cible dans `desc()`. Donc, par exemple, pour trier par sexe et poids, mais avec les personnes les plus lourdes en haut, nous pouvons exécuter :

```
e_poids %>%
ge(sexe, desc(poids_kg))
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female      162
## 2 Female      161
## 3 Female      158
## 4 Female      135
## 5 Female      129
```

PRACTICE

Pratique 1

Avec une commande `arrange()`, triez les données `sarcopenia` d'abord par sexe, puis par force de préhension. (Si c'est fait correctement, la première ligne devrait être celle d'une femme avec une force de préhension de 1,3 kg). Pour rendre l'organisation claire, vous devriez d'abord `select()` les variables de sexe et de force de préhension.

```
étez le code avec votre réponse :

ıia %>%
(_____________________________________) %>%
ge(_____________________________________)
```

Pratique 2

Le jeu de données `sarcopenia` contient une colonne `groupe_d_age`, qui stocke les groupes d'âge en chaîne de caractères (les groupes d'âge sont "Sixties", "Seventies" et "Eighties"). Convertissez cette variable en un facteur avec les niveaux dans le bon ordre (d'abord "Sixties", puis "Seventies" et ainsi de suite). (Astuce : Revenez sur la leçon `case_when()` si vous ne voyez pas comment réattribuer un niveau à un facteur).

Ensuite, avec une commande imbriquée à `arrange()`, classez les données d'abord par la variable facteur `groupe_d_age` nouvellement créée (les individus les plus jeunes en premier) puis par `taille_metres`, avec les individus les plus petits en premier.

```
étez le code avec votre réponse :

ıia %>%
```

Filtrage par groupe

La fonction `filter()` conserve ou supprime des lignes en fonction d'une condition. Si `filter()` est appliquée à des données groupées, l'opération de filtrage est réalisée séparément pour chaque groupe.

Pour illustrer cela, considérons à nouveau le jeu de données `yao_sexe_poids` :

```
e_poids
```

```
## # A tibble: 5 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female       95
## 2 Male         96
## 3 Male         74
## 4 Female       70
## 5 Female       67
```

Si nous voulons filtrer les données pour la personne la plus lourde, nous pourrions exécuter :

```
e_poids %>%
r(poids_kg == max(poids_kg))
```

```
## # A tibble: 1 × 2
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Female      162
```

Mais si nous voulons obtenir la personne la plus lourde par groupe de sexe (l'homme le plus lourd *et* la femme la plus lourde), nous pouvons utiliser `group_by(sex)` puis `filter()` :

```
e_poids %>%
_by(sexe) %>%
r(poids_kg == max(poids_kg))
```

```
## # A tibble: 2 × 2
## # Groups:   sexe [2]
##   sexe   poids_kg
##   <chr>     <dbl>
## 1 Male        128
## 2 Female      162
```

Parfait ! Le code ci-dessus peut être traduit par "Pour chaque groupe de sexe, conserve la ligne avec la valeur maximale `poids_kg`".

Filtrage avec des groupements imbriqués

La fonction `filter()` fonctionne bien avec un nombre quelconque de groupements imbriqués.

Par exemple, si nous voulons voir l'homme le plus lourd et la femme la plus lourde *par groupe d'âge*, nous pourrions exécuter le code suivant sur le jeu de données `yao`

:

```
_by(sexe, cat_age) %>%
r(poids_kg == max(poids_kg))
```

Ce code regroupe par sexe *et* catégorie d'âge, puis trouve la personne la plus lourde dans chaque sous-catégorie.

(Pourquoi avons-nous 10 lignes dans la sortie ? Eh bien, 2 groupes de sexe x 5 groupes d'âge = 10 groupements uniques.)

La sortie est un peu dispersée, donc nous pouvons enchaîner cela avec la fonction `arrange()`, pour organiser par sexe et groupe d'âge.

```
_by(sexe, cat_age) %>%
r(poids_kg == max(poids_kg)) %>%
ge(sexe, cat_age)
```

Maintenant, les données sont plus faciles à lire. Toutes les femmes viennent en premier, puis les hommes. Mais nous remarquons un arrangement étrange des groupes d'âge ! Ceux âgés de 5 à 14 ans devraient venir *en premier* dans l'arrangement. Bien sûr, nous avons appris comment corriger cela avec la fonction `factor()` et son argument `levels` :

```
e(cat_age = factor(
_age,
els = c("5 - 14", "15 - 29", "30 - 44", "45 - 64", "65 +")
%
_by(sexe, cat_age) %>%
r(poids_kg == max(poids_kg)) %>%
ge(sexe, cat_age)
```

Maintenant, nous avons une sortie bien organisée !

Pratique 3

Groupez le jeu de données `sarcopenia` par groupe d'âge et sexe, puis filtrez pour obtenir l'index de masse musculaire le plus élevé dans chaque groupe (imbriqué).

```
étez le code avec votre réponse :

ıia
```

Modification par groupe

`mutate()` est utilisé pour modifier les colonnes ou pour en créer de nouvelles. Avec des données groupées, `mutate()` opère sur chaque groupe indépendamment.

Considérons d'abord un appel régulier à `mutate()`, pas un groupé. Imaginez que vous voulez ajouter une colonne qui classe les répondants par poids. Cela peut être fait avec la fonction `rank()` à l'intérieur d'un appel à `mutate()` :

```
e_poids %>%
e(poids_ordre = rank(poids_kg))
```

```
## # A tibble: 5 × 3
##   sexe   poids_kg poids_ordre
##   <chr>     <dbl>       <dbl>
## 1 Female       95         901
## 2 Male         96         908
## 3 Male         74         640.
## 4 Female       70         564.
## 5 Female       67         502.
```

La sortie montre que la première ligne est le 901ème individu le plus léger. Mais il serait plus intuitif de classer dans l'ordre décroissant avec la personne la plus lourde en premier. Nous pouvons le faire avec la fonction `desc()` :

```
e_poids %>%
e(poids_ordre = rank(desc(poids_kg)))
```

```
## # A tibble: 5 × 3
##   sexe   poids_kg poids_ordre
##   <chr>     <dbl>       <dbl>
## 1 Female       95          71
## 2 Male         96          64
## 3 Male         74         332.
## 4 Female       70         408.
## 5 Female       67         470.
```

La sortie montre que la personne de la première ligne est la 71ème personne la plus lourde.

Maintenant, essayons d'écrire un appel groupé à `mutate()`. Imaginez que nous voulons ajouter cette colonne de classement par poids *par groupe de sexe* dans le jeu de données. Autrement dit, nous voulons connaître le classement de chaque personne par poids dans leur catégorie de sexe. Dans ce cas, nous pouvons combiner `group_by(sex)` avec `mutate()` :

```
e_poids %>%
 by(sexe) %>%
e(poids_ordre = rank(desc(poids_kg)))
```

```
## # A tibble: 5 × 3
## # Groups:   sexe [2]
##   sexe   poids_kg poids_ordre
##   <chr>     <dbl>       <dbl>
## 1 Female       95        53.5
## 2 Male         96        13.5
## 3 Male         74       148
## 4 Female       70       220.
## 5 Female       67       250.
```

Nous voyons maintenant que la personne de la première ligne est la 53ème femme la plus lourde. (Le .5 indique que ce rang est à égalité avec quelqu'un d'autre dans les données.)

Nous pourrions également organiser les données pour rendre les choses plus claires :

```
e_poids %>%
 by(sexe) %>%
e(poids_ordre = rank(desc(poids_kg))) %>%
ge(sexe, poids_ordre)
```

```
## # A tibble: 5 × 3
## # Groups:   sexe [1]
##   sexe   poids_kg poids_ordre
##   <chr>     <dbl>       <dbl>
## 1 Female      162           1
## 2 Female      161           2
## 3 Female      158           3
## 4 Female      135           4
## 5 Female      129           5
```

Modification avec des groupes imbriqués

Bien sûr, comme avec les autres verbes que nous avons vus, `mutate()` fonctionne aussi avec des groupes imbriqués.

Par exemple, ci-dessous nous créons le groupe imbriqué d'âge *et* de sexe avec le jeu de données `yao`, puis nous ajoutons une colonne de rang avec `mutate()` :

```
 by(sexe, cat_age) %>%
e(poids_ordre = rank(desc(poids_kg)))
```

```
## # A tibble: 5 × 8
## # Groups:   sexe, cat_age [4]
##   sexe     age cat_age poids_kg occupation      resultat_igg
##   <chr>  <dbl> <chr>      <dbl> <chr>           <chr>
## 1 Female    45 45 - 64       95 Informal worker Negative
## 2 Male      55 45 - 64       96 Salaried worker Positive
## 3 Male      23 15 - 29       74 Student         Negative
## 4 Female    20 15 - 29       70 Student         Positive
## 5 Female    55 45 - 64       67 Trader--Farmer  Positive
## # ℹ 2 more variables: resultat_igm <chr>, poids_ordre <dbl>
```

La sortie montre que la personne de la première ligne est la 20ème femme la plus lourde *dans le groupe d'âge de 45 à 64 ans*.

Pratique 4

Avec les données `sarcopenia`, groupez par `groupe_d_age`, puis dans une nouvelle variable appelée `force_prehension_ordre`, calculez le rang de la force de préhension de chaque individu par groupe d'âge. (Pour calculer le rang, utilisez `mutate()` et la fonction `rank()` avec sa méthode par défaut pour les égalités.)

```
étez le code avec votre réponse :

ıia
```

Attention

N'oubliez pas de dégrouper les données avant de procéder à une analyse plus approfondie

Comme il a été mentionné auparavant, il est important de dégrouper vos données avant de faire une analyse plus détaillée.

Considérez ce dernier exemple, où nous avons calculé le rang de poids des individus par groupe d'âge et de sexe :

```
_by(sexe, cat_age) %>%
e(poids_ordre = rank(desc(poids_kg)))
```

```
## # A tibble: 5 × 8
## # Groups:   sexe, cat_age [4]
##   sexe     age cat_age poids_kg occupation
resultat_igg
##   <chr>  <dbl> <chr>      <dbl> <chr>           <chr>
## 1 Female    45 45 - 64       95 Informal worker Negative
## 2 Male      55 45 - 64       96 Salaried worker Positive
## 3 Male      23 15 - 29       74 Student         Negative
## 4 Female    20 15 - 29       70 Student         Positive
## 5 Female    55 45 - 64       67 Trader--Farmer  Positive
## # ℹ 2 more variables: resultat_igm <chr>, poids_ordre <dbl>
```

Si, dans le processus d'analyse, vous avez stocké cette sortie comme un nouveau jeu de données :

```
.fie <-
>%
_by(sexe, cat_age) %>%
e(poids_ordre = rank(desc(poids_kg)))
```

WATCH OUT

Et puis, plus tard, vous avez repris le jeu de données et essayé une autre analyse, par exemple, en filtrant pour obtenir la personne la plus âgée dans les données :

```
.fie %>%
r(age == max(age))
```

```
## # A tibble: 5 × 8
## # Groups:   sexe, cat_age [5]
##   sexe     age cat_age poids_kg occupation
resultat_igg
##   <chr>  <dbl> <chr>      <dbl> <chr>           <chr>
## 1 Male      65 45 - 64       93 Retired         Negative
## 2 Male      78 65 +          95 Retired--Infor… Positive
## 3 Male      14 5 - 14        44 Student         Negative
## 4 Female    44 30 - 44       67 Home-maker      Positive
## 5 Female    79 65 +          40 Retired         Negative
## # ℹ 2 more variables: resultat_igm <chr>, poids_ordre <dbl>
```

Vous pourriez être confus par la sortie! Pourquoi y a-t-il 55 lignes de "personnes les plus âgées"?

Cela serait dû au fait que vous avez oublié de dégrouper les données avant de les stocker pour une analyse plus approfondie. Faisons cela correctement maintenant

```
.fie <-
>%
 by(sexe, cat_age) %>%
e(poids_ordre = rank(desc(poids_kg)))%>%
up()
```

Maintenant, nous pouvons obtenir correctement la/les personne(s) la/les plus âgée(s) dans le jeu de données :

```
.fie %>%
r(age == max(age))
```

```
## # A tibble: 2 × 8
##   sexe     age cat_age poids_kg occupation resultat_igg
##   <chr>  <dbl> <chr>       <dbl> <chr>      <chr>
## 1 Female    79 65 +           40 Retired    Negative
## 2 Female    79 65 +           81 Home-maker Negative
## # ℹ 2 more variables: resultat_igm <chr>, poids_ordre <dbl>
```

Conclusion

`group_by()` est un outil merveilleux pour arranger, modifier, filtrer en fonction des groupes au sein d'une ou plusieurs variables.

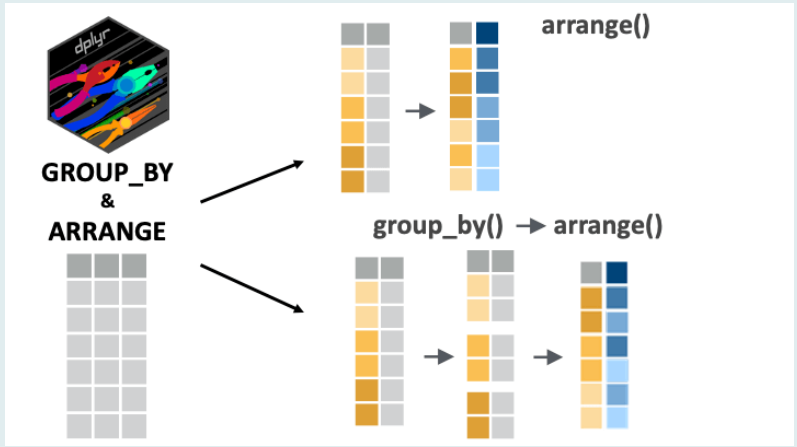

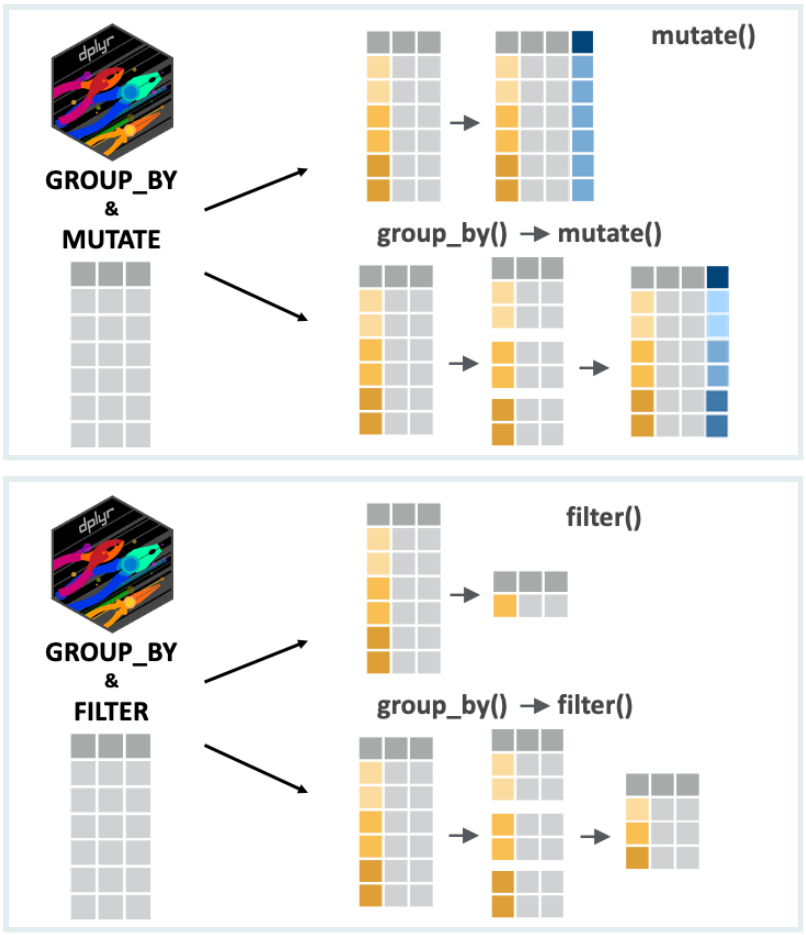

Fig: filter() et son utilisation combinée avec group_by()

Il existe de nombreuses façons de combiner ces verbes pour manipuler vos données. Nous vous invitons à prendre un peu de temps pour essayer ces verbes dans différentes combinaisons !

À la prochaine !

Contributeurs

Les membres de l'équipe suivants ont contribué à cette leçon :

LAURE VANCAUWENBERGHE

Data analyst, the GRAPH Network
A firm believer in science for good, striving to ally programming, health and education

KENE DAVID NWOSU

Data analyst, the GRAPH Network

Passionate about world improvement

GUY WAFEU

R Instructor and Public Health Physician
Committed to improving the quality of data analysis

Références

Certains matériaux de cette leçon ont été adaptés des sources suivantes :

- Horst, A. (2022). *Dplyr-learnr*. https://github.com/allisonhorst/dplyr-learnr (Travail original publié en 2020)
- *Grouper par une ou plusieurs variables*. (n.d.). Consulté le 21 Février 2022, sur https://dplyr.tidyverse.org/reference/group_by.html
- *Créer, modifier et supprimer des colonnes — Mutate*. (n.d.). Consulté le 21 Février 2022, sur https://dplyr.tidyverse.org/reference/mutate.html
- *Sélectionner des lignes en utilisant les valeurs des colonnes — Filter*. (n.d.). Consulté le 21 Février 2022, sur https://dplyr.tidyverse.org/reference/filter.html
- *Arranger les lignes par valeurs de colonnes — Arrange*. (n.d.). Consulté le 21 Février 2022, sur https://dplyr.tidyverse.org/reference/arrange.html

L'œuvre d'art a été adaptée de :

- Horst, A. (2022). *Illustrations R & stats par Allison Horst*. https://github.com/allisonhorst/stats-illustrations (Travail original publié en 2018)

Solutions des exercices pratiques

Solution exercice pratique 1

```
ıia %>%
(sexe_homme_1_femme_0, force_de_prehension_kg) %>%
ge(sexe_homme_1_femme_0, force_de_prehension_kg)
```

Solution exercice pratique 2

```
ıia %>%
e(groupe_d_age = factor(groupe_d_age, levels = c("Sixties",
                                                 "Seventies",
                                                 "Eighties"))) %>%
ge(groupe_d_age, taille_metres)
```

Solution exercice pratique 3

```
ıia %>%
_by(groupe_d_age,sexe_homme_1_femme_0) %>%
:(index_de_muscle_squelettique == max(index_de_muscle_squelettique))
```

Solution exercice pratique 4

```
ıia %>%
_by(groupe_d_age) %>%
e(force_prehension_ordre = rank(force_de_prehension_kg))
```